

รายงาน

Human Filter for Video

Model Compression and Optimization of Robust Video Matting for Edge Computing

เสนอ

ผศ. ดร. จิรายุ เพชรแหน

รายชื่อสมาชิก:

66011454 ภูมิรพี อาภาคัพภะกุล

66010882 สุวิจักขณ์ หยกพิทักษ์โชค

โครงการนี้เป็นส่วนหนึ่งของรายวิชา AI for edge computing

Introduction

ปัจจุบันเทคนิค Computer Vision ถูกนำไปประยุกต์ใช้กับการประมวลผลภาพและวิดีโอในหลากหลายรูปแบบ เช่น การตรวจจับบุคคล การแยกวัตถุ การเปลี่ยนฉากหลังของการประชุมออนไลน์ และการวิเคราะห์ข้อมูลจากกล้องวงจรปิด

หนึ่งในงานที่มีความสำคัญคือ Human Segmentation ซึ่งเป็นกระบวนการระบุพื้นที่ของบุคคลภายในภาพในระดับพิกเซล โดยผลลัพธ์สามารถนำไปประยุกต์ใช้กับระบบเปลี่ยนพื้นหลัง การสร้าง Visual Effects และการลบวัตถุออกจากวิดีโอ

อย่างไรก็ตาม การลบบุคคลออกจากวิดีโอให้ดูเหมือนไม่เคยมีบุคคลอยู่ในฉาก จำเป็นต้องดำเนินการมากกว่าการสร้าง Segmentation Mask เนื่องจากพื้นที่ที่ถูกบุคคลบดบังไม่มีข้อมูลฉากหลังที่มองเห็นได้โดยตรง ระบบจึงต้องมีขั้นตอน Background Reconstruction หรือ Video Inpainting เพื่อเติมข้อมูลภาพในบริเวณดังกล่าวโครงงานนี้จึงใช้การสร้าง Human Segmentation Mask เป็นองค์ประกอบแรกของระบบ Real-Time Human Removal ที่ต้องการพัฒนาต่อไปโมเดล Robust Video Matting (RVM) ถูกเลือกเป็นพื้นฐานเนื่องจากมีสถาปัตยกรรมสำหรับการประมวลผลวิดีโออย่างต่อเนื่อง โดยมี Recurrent States เพื่อเก็บข้อมูลจากเฟรมก่อนหน้า ซึ่งเหมาะสำหรับงานที่ต้องประมวลผลภาพหลายเฟรมติดต่อกัน

ถึงแม้ RVM จะสามารถทำงานบน GPU ที่มีสมรรถนะสูงได้ แต่การนำไปใช้งานบน Edge Device เช่น NVIDIA Jetson Nano ยังคงต้องพิจารณาข้อจำกัดด้านหน่วยความจำ ขนาดโมเดล Latency และความเข้ากันได้ของ Runtime

ดังนั้นโครงงานนี้จึงศึกษาการลดความซับซ้อนของโมเดลผ่านเทคนิค Model Compression และ Optimization เพื่อเตรียมโมเดล Segmentation ให้เหมาะสมต่อการนำไปใช้ในระบบ Real-Time Human Removal ในอนาคต

Project Objectives

วัตถุประสงค์ของ Final Project ประกอบด้วย

1. ศึกษาผลของการเลือก MobileNet Backbone ต่อความแม่นยำและประสิทธิภาพการประมวลผลของ RVM
2. พัฒนาโมเดลที่ผ่านการ Fine-tuning จาก Pretrained Weights โดยใช้ข้อมูล Human Segmentation
3. ศึกษา Model Compression ผ่าน Unstructured Pruning, Low-Rank Approximation และ Channel Slimming
4. ใช้ Knowledge Distillation สำหรับ Recovery Training ของโมเดลที่ผ่าน Compression
5. ปรับปรุงความทนทานของโมเดลต่อความแตกต่างของภาพด้วย Data Augmentation
6. ลดขนาดโมเดลด้วย FP16 และทดสอบ ONNX Export
7. ประเมินความแม่นยำ ขนาดโมเดล และความเร็วภายใต้ Benchmark Protocol ที่กำหนด
8. วิเคราะห์ข้อจำกัดก่อนนำโมเดลไปใช้งานบน Edge Device
9. วางแนวทางต่อยอดโมเดล Segmentation ไปสู่ระบบ Real-Time Human Removal

Expected Outcomes

ผลลัพธ์ที่ต้องการคือโมเดล Segmentation ที่มีจำนวนพารามิเตอร์ลดลง สามารถรักษาความแม่นยำตามเกณฑ์ Validation IoU และมี Runtime Performance ที่เหมาะสมกับการประมวลผลแบบต่อเนื่อง

อีกหนึ่งผลลัพธ์ที่สำคัญคือ Experimental Pipeline ที่สามารถนำไปทดสอบ Compression Methods ต่าง ๆ โดยเก็บ Training Configurations, Model Artifacts และ Benchmark Results อย่างตรวจสอบย้อนกลับได้

สำหรับการต่อยอดในอนาคต ระบบควรสามารถรับวิดีโอจากกล้อง สร้าง Human Mask และใช้ Mask ดังกล่าว ควบคุมกระบวนการ Background Reconstruction เพื่อสร้าง Output Video ที่ไม่มีบุคคลอยู่ในฉาก

Dataset and Data Preparation

2.1 Dataset Description

โครงงานใช้ Supervisely Person Dataset ซึ่งประกอบด้วยภาพ RGB และ Ground Truth Masks สำหรับ Human Segmentation ข้อมูลทั้งหมดประกอบด้วย 2,667 คู่ภาพและ Mask โดยแต่ละคู่มีความสัมพันธ์ผ่าน Sample Identifier โดย Input Data เป็น RGB Image ซึ่งมีข้อมูลสาม Channels ได้แก่ Red, Green และ Blue และTarget Data เป็น Binary Segmentation Mask ซึ่งใช้ระบุบริเวณที่เป็นบุคคลและพื้นหลัง

DATASET PROPERTY	VALUE
DATASET	Supervisely Person Dataset
TOTAL SAMPLES	2,667
INPUT TYPE	RGB Image
LABEL TYPE	Binary Segmentation Mask
TRAINING RESOLUTION	256×256
MAIN TASK	Human Segmentation
PRIMARY METRICS	IoU, Dice

2.2 Dataset Splitting

การทดลอง Final Model ใช้ Data Split ตาม Midterm Notebook โดยแบ่งเป็นสามส่วน

PARTITION	SAMPLES
TRAINING	2,133
VALIDATION	266
TESTING	268
TOTAL	2,66

Training Set ใช้สำหรับปรับค่าพารามิเตอร์ระหว่าง Fine-tuning และ Knowledge Distillation

Validation Set ใช้สำหรับเลือก Best Checkpoint และพิจารณาว่าโมเดลผ่าน Accuracy Constraint หรือไม่

Test Set ใช้สำหรับประเมินความสามารถของ Final Model บนข้อมูลที่ไม่ถูกนำมาใช้ในกระบวนการ Model Selection

2.3 Data Preprocessing

ขั้นตอนการเตรียมข้อมูลประกอบด้วยการแปลงภาพเป็น RGB และปรับขนาดให้เหมาะสมกับโมเดล สำหรับ Input Images ใช้ Bilinear Interpolation ในการปรับขนาด ขณะที่ Ground Truth Masks ใช้ Nearest-Neighbor Interpolation เพื่อรักษาความถูกต้องของ Class Labels ข้อมูลภาพถูกแปลงให้อยู่ในช่วง 0–1 และนำมาใช้เป็น Input Tensors ของโมเดล และ Ground Truth Mask ถูกแปลงเป็น Binary Values เพื่อใช้คำนวณ Supervised Segmentation Loss และ Evaluation Metrics และสำหรับ Benchmark ที่ 512×512 ใช้ Validation Samples ชุดเดิมแต่ปรับ Input Resolution เพิ่มขึ้น ไม่ได้เป็นการสร้างชุดข้อมูลใหม่หรือฝึกโมเดลใหม่

2.4 Data Augmentation

เพิ่ม Gaussian Blur และ Gaussian Noise เพื่อให้โมเดลมีโอกาสเรียนรู้จากภาพที่มีความแตกต่างด้านความคมชัดและสัญญาณรบกวน Gaussian Blur ถูกสุ่มใช้กับภาพ Training ด้วยความน่าจะเป็น 25% และกำหนด Radius อยู่ในช่วง 0.3–1.2 Gaussian Noise ถูกสุ่มใช้ด้วยความน่าจะเป็น 35% และมี Standard Deviation อยู่ในช่วง 0.01–0.05 บนช่วงค่าพิกเซล 0–1

ทั้งสอง Augmentations ถูกสุ่มแยกจากกันและอาจเกิดขึ้นพร้อมกันในภาพเดียวกันได้ การเพิ่ม Blur และ Noise จะเปลี่ยนเฉพาะ Input Image โดยไม่ปรับ Ground Truth Mask สำหรับ Validation และ Test Data จะไม่ใช้ Random Augmentation เพื่อให้การประเมินมีความสม่ำเสมอและสามารถเปรียบเทียบระหว่างโมเดลได้

Baseline Model and Midterm Experiments

3.1 Robust Video Matting Architecture

Robust Video Matting หรือ RVM เป็นโมเดลสำหรับแยกบุคคลออกจากพื้นหลังของวิดีโอ โดยใช้โครงสร้าง Encoder–Decoder ร่วมกับ Recurrent States

Encoder ทำหน้าที่สกัด Visual Features จากภาพ Input

ASPP ใช้รวบรวมข้อมูลเชิงพื้นที่จากหลายระดับความละเอียด

Recurrent Decoder ใช้สร้าง Output โดยนำ Feature ของเฟรมปัจจุบันมาประมวลผลร่วมกับข้อมูลจากเฟรมก่อนหน้า

ภายในระบบประกอบด้วย Recurrent States จำนวน 4 ชุด ซึ่งช่วยส่งข้อมูลระหว่างเฟรมอย่างต่อเนื่อง

ในการทดลองนี้ใช้ส่วน Segmentation Output เพื่อสร้าง Binary Human Mask ไม่ได้ทำการประเมิน Alpha Matting Quality ของสถาปัตยกรรมต้นฉบับโดยตรง

3.2 Baseline Backbone Comparison

ในการทดลอง ได้เปรียบเทียบ MobileNet Backbone จำนวน 4 รูปแบบ

BACKBONE	IOU / DICE	MEAN LATENCY	GPU FPS
MOBILENETV3-LARGE	0.93322 / 0.96546*	14.319 ms	69.84
MOBILENETV3-SMALL	0.91194 / 0.95394*	11.954 ms	83.66
MOBILENETV2	0.92794 / 0.96262*	12.199 ms	81.98
MOBILENETV1	0.93345 / 0.96558*	9.074 ms	110.21

ผลการทดลองพบว่า MobileNetV1 มีความแม่นยำและ GPU FPS สูงที่สุด ขณะที่ MobileNetV3-Small มีจำนวน Parameters ต่ำที่สุดและ CPU FPS สูงที่สุด

MobileNetV3-Large มีความแม่นยำใกล้เคียง MobileNetV1 แต่ใช้ Parameters และ GFLOPs น้อยกว่า

ผลลัพธ์แสดงให้เห็นว่า Model Size และ Computational Complexity ไม่ได้สัมพันธ์โดยตรงกับ Inference Speed ซึ่งขึ้นอยู่กับสถาปัตยกรรมและ Hardware Runtime ที่ใช้ด้วย

3.3 Baseline Selection for Final Project

จากผลการทดลอง Midterm ได้เลือก **RVM-MobileNetV3-Large** เป็น Reference Model สำหรับ Final Project แม้จะไม่ใช่โมเดลที่เร็วที่สุด เนื่องจากมีความแม่นยำสูง และมี Official Pretrained RVM Weights ที่เหมาะสำหรับนำมาศึกษาการลดความซับซ้อนของโมเดล

ในการทดลอง Final Project จะใช้โมเดลนี้เป็น Baseline สำหรับเปรียบเทียบกับโมเดลที่ผ่าน Model Compression ได้แก่

- **Model A:** SVD50 + Knowledge Distillation
- **Model B:** SLIM50 + SVD50 + Knowledge Distillation

การทดลองมีเป้าหมายลดจำนวน Parameters และ Model Size โดยรักษา Segmentation Accuracy ให้อยู่ในระดับที่ยอมรับได้ เพื่อเตรียมโมเดลสำหรับนำไปใช้เป็นส่วน Human Detection/Segmentation ของระบบลบบุคคลออกจากวิดีโอแบบ Real-Time

Model Compression and Optimization

4.1 Optimization Strategy

การทดลอง Model Compression เริ่มต้นจาก Fine-tuned RVM-MobileNetV3-Large โดยประยุกต์เทคนิคการลดความซับซ้อนของโมเดล แล้วดำเนินการ Recovery Training เพื่อรักษาความแม่นยำ

เทคนิคที่ศึกษา ได้แก่ Unstructured Pruning, Low-Rank Approximation, Channel Slimming และ Knowledge Distillation

จากนั้นจึงนำ Candidate ที่เลือกไปแปลงเป็น FP16 และ ONNX เพื่อประเมินประสิทธิภาพด้าน Model Size และ Runtime

4.2 Unstructured Pruning

Unstructured Pruning เป็นเทคนิคที่กำหนดให้น้ำหนักบางส่วนของโมเดลเป็นศูนย์ โดยเลือกจาก Weight Magnitude การทดลองประกอบด้วย UP40 และ UP70 ซึ่งกำหนด Sparsity เท่ากับ 40% และ 70% ของ Eligible Weights

แม้เทคนิคดังกล่าวสามารถลด Non-Zero Weights ได้ แต่ไม่ได้ลดจำนวน Parameters หรือขนาด Dense Checkpoint โดยตรง เนื่องจาก Tensor Shape ยังคงเดิม

4.3 Low-Rank Approximation (SVD)

Low-Rank Approximation ใช้ Singular Value Decomposition (SVD) เพื่อประมาณ Weight Matrix ด้วย Matrix Factors ที่มี Rank ต่ำกว่า ในการทดลอง SVD50 ใช้ Rank Ratio เท่ากับ 0.5 กับ Convolution Layers ที่เข้าเงื่อนไข โดยเลือกเฉพาะ Layer ที่การ Factorization ช่วยลดจำนวน Parameters ได้จริง เทคนิคนี้สามารถลด Structural Parameters ของโมเดล แต่ต้องใช้ Recovery Training เพื่อลดผลกระทบต่อ Prediction Accuracy

4.4 Channel Slimming

Channel Slimming เป็นเทคนิคที่ลดจำนวน Feature Channels ใน Neural Network โดยในโครงงานนี้มุ่งเน้นส่วน Recurrent Decoder การทดลองมี SLIM75 และ SLIM50 โดยลด Decoder Width ตามอัตราส่วนที่กำหนด การลด Channels ทำให้ขนาด Tensor และจำนวน Parameters ลดลงจริง แต่ก็อาจส่งผลต่อความสามารถในการเก็บ Spatial และ Temporal Features ของโมเดล

4.5 Knowledge Distillation

Knowledge Distillation (KD) เป็นกระบวนการถ่ายทอดความรู้จาก Teacher Model ไปยัง Student Model

Teacher Model ในการทดลองคือ Original Fine-tuned RVM-MobileNetV3-Large ส่วน Student Models คือโมเดลที่ผ่าน Structural Compression

ระหว่างการฝึก Student จะเรียนรู้จาก Ground Truth Segmentation Mask และ Teacher Predictions ร่วมกัน

แนวทางนี้ใช้ช่วยรักษาความแม่นยำหลัง Compression โดยไม่เพิ่มจำนวน Parameters ของ Student Model ในขั้นตอน Inference

4.6 Final Compression Models

จากการทดลองได้เลือกโมเดลสองรูปแบบสำหรับ Final Comparison

MODEL	COMPRESSION METHOD	OBJECTIVES
BASELINE	Original RVM-MobileNetV3-Large	Reference Model
MODEL A	SVD50 + KD	ลด Parameters โดยเน้นรักษา Accuracy
MODEL B	SLIM50 + SVD50 + KD	ลด Parameters เพิ่มเติมด้วย Hybrid Compression

Model A ลดจำนวน Parameters ผ่าน Low-Rank Approximation

Model B ใช้ Channel Slimming ร่วมกับ SVD เพื่อบีบอัดโครงสร้างเพิ่มเติม

ทั้งสองโมเดลได้รับ Recovery Training และใช้ Knowledge Distillation เพื่อช่วยรักษาความสามารถในการทำนาย

4.7 FP16 and ONNX Optimization

หลัง Compression มีการลด Precision ของโมเดลจาก FP32 เป็น FP16 เพื่อลด Model Storage นอกจากนี้ยังทดลองแปลงโมเดลเป็น ONNX ซึ่งสามารถนำไปประมวลผลผ่าน ONNX Runtime

เนื่องจาก RVM เป็น Stateful Model การ Export ต้องรองรับ Recurrent State Inputs และ Outputs จำนวน 4 ชุด

ก่อนนำไปใช้งานจริงต้องตรวจสอบ Numerical Parity ระหว่าง PyTorch และ ONNX เพื่อยืนยันว่าการ Export ไม่ทำให้ผลทำนายเปลี่ยนแปลงเกินเกณฑ์ที่ยอมรับได้

Experimental Setup and Evaluation

5.1 Experimental Environment

การทดลอง Final Model ใช้ PyTorch สำหรับ Training และ Evaluation และใช้ ONNX Runtime สำหรับการทดสอบ Exported Models

Hardware หลักสำหรับ GPU Benchmark คือ NVIDIA GeForce RTX 5070 Ti Laptop GPU

การทดลอง PyTorch FP16 และ ONNX FP16 ถูกประเมินแยกกัน เนื่องจาก Inference Performance ขึ้นอยู่กับ Runtime และ Execution Provider

5.2 Training Configuration

การฝึกโมเดลใช้ Supervised Segmentation Loss ร่วมกับ Knowledge Distillation Loss

Supervised Loss ประกอบด้วย Binary Cross-Entropy และ Dice Loss ดังนี้

$$\left[L_{seg} = 0.8L_{BCE} + 0.2L_{Dice}\right]$$

Total Loss สำหรับการฝึกด้วย Knowledge Distillation คือ

$$\left[L_{total} = (1-\alpha)L_{seg} + \alpha L_{KD}\right]$$

โดย Training Configuration ใช้ค่าเริ่มต้น KD Weight เท่ากับ 0.2 และ Temperature เท่ากับ 2.0

การฝึก Final Models รอบล่าสุดได้ผลดังนี้

MODEL	TRAINING EPOCHS	BEST EPOCH
MODEL A	23	18
MODEL B	50	47

โมเดลทั้งสองใช้ Gaussian Blur และ Gaussian Noise ระหว่าง Training โดยเลือก Best Checkpoint จาก Validation Performance

5.3 Evaluation Metrics

Intersection over Union (IoU) ใช้วัดความสอดคล้องของพื้นที่ Foreground ระหว่าง Prediction และ Ground Truth

$$\left[IoU = \frac{TP}{TP + FP + FN}\right]$$

Dice Score ใช้วัดความคล้ายคลึงของ Segmentation Masks

$$\left[Dice = \frac{2TP}{2TP + FP + FN}\right]$$

Parameter Reduction ใช้วัดสัดส่วนจำนวน Parameters ที่ลดลงเมื่อเทียบกับ Original Baseline

Model Size ใช้วัดขนาด Artifact จริงที่จัดเก็บในรูป FP32, FP16 หรือ ONNX

Inference Latency วัดระยะเวลาประมวลผลต่อ Inference Call เป็น Milliseconds

FPS ใช้วัดจำนวนเฟรมที่โมเดลประมวลผลได้ต่อวินาทีภายใต้ Benchmark Protocol

Numerical Parity ใช้ประเมินความแตกต่างของ Outputs ระหว่าง PyTorch และ ONNX โดยเฉพาะเมื่อส่ง Recurrent States ต่อเนื่องหลายเฟรม

5.4 Model Selection Criteria

กำหนดให้โมเดลที่ผ่าน Compression สามารถมี Validation IoU ลดลงจาก Baseline ได้ไม่เกิน 10 percentage points

Baseline Validation IoU เท่ากับ 0.9282666 ดังนั้นเกณฑ์ขั้นต่ำคือ

$$[IoU_{minimum} = 0.93322 - 0.10 = 0.83322\ ]$$

โมเดลที่มี Validation IoU สูงกว่าหรือเท่ากับเกณฑ์นี้ถือว่าผ่าน Accuracy Constraint

อย่างไรก็ตาม การผ่าน Accuracy Constraint ไม่ได้ยืนยันว่าโมเดลพร้อม Deployment เนื่องจากยังต้องตรวจสอบ Numerical Parity และ Runtime Compatibility เพิ่มเติม

Experimental Results

Exploratory Compression Results

การทดลอง Compression Search รุ่นแรกใช้เพื่อเปรียบเทียบเทคนิคต่าง ๆ ก่อนเลือก Final Models

COMPRESSION METHOD	VALIDATION IOU	PARAMETERS	FP32 CHECKPOINT SIZE
CONTROL	0.93309	3,747,757	15.210 MB
UP40	0.93164	3,747,757	15.210 MB
UP70	0.89993	3,747,757	15.210 MB
SVD50	0.93228	3,397,417	13.814 MB
SLIM75	0.91287	3,638,956	14.775 MB
SLIM50	0.90855	3,551,287	14.423 MB
SLIM50 + SVD50	0.91157	3,293,525	13.396 MB

จากผลการทดลอง SVD50 สามารถลดจำนวน Parameters โดยรักษา Validation IoU ใกล้เคียง CONTROL

การใช้ Unstructured Pruning ไม่ได้ลด Dense Checkpoint Size ส่วน Hybrid Compression สามารถลดขนาดเชิงโครงสร้างได้มากกว่า

Final Model Accuracy

MODEL	FP32 VALIDATION IOU	FP16 VALIDATION IOU	FP16 DICE
BASELINE	0.92827	—	—
MODEL A	0.94214	0.94212	0.96920
MODEL B	0.93218	0.93220	0.96351

Model A มีค่า Validation IoU สูงที่สุด โดยมีค่า FP16 IoU เท่ากับ 0.94212

Model B มีค่า FP16 IoU เท่ากับ 0.93220 ซึ่งสูงกว่า Baseline FP32 Validation IoU เล็กน้อย

ทั้งสองโมเดลผ่าน Accuracy Constraint ที่กำหนดไว้

Parameter Reduction and Model Size

METRIC	BASELINE	MODEL A	MODEL B
PARAMETERS	3,747,757	3,397,417	3,293,525
PARAMETER REDUCTION	—	9.35%	12.12%
ONNX FP16 SIZE (256×256 EXPORT)	7.564 MB	6.870 MB	6.661 MB

Model A ลด Parameters ได้ 9.35% ขณะที่ Model B ลดได้ 12.12%

ผลดังกล่าวแสดงว่า Hybrid Compression ของ Model B สามารถลดจำนวน Parameters ได้มากกว่า SVD50 เพียงอย่างเดียว

เมื่อพิจารณาขนาด ONNX FP16 Artifact พบว่า Model B มีขนาดเล็กที่สุดในกลุ่ม Final Models

PyTorch FP16 Inference Performance

ผลการทดสอบ PyTorch FP16 บน RTX 5070 Ti Laptop GPU ที่ 256×256 เป็นดังนี้

METRIC	MODEL A	MODEL B
P50 LATENCY	7.46 ms	7.11 ms
P95 LATENCY	10.65 ms	10.26 ms
FPS	125.3	131.0

Model B มีค่า FPS สูงกว่า Model A และมี Inference Latency ต่ำกว่าเล็กน้อย ผลลัพธ์นี้แสดงให้เห็นว่า Model B มีประสิทธิภาพ Model-Only Inference สูงกว่า Model A ในการทดลองดังกล่าว อย่างไรก็ตาม ผลนี้ยังไม่รวม Camera Capture, Preprocessing, Background Reconstruction และ Rendering

ONNX FP16 Benchmark at 512×512

การทดลอง ONNX FP16 ใช้ Input Resolution 512×512 โดยใช้ Checkpoints ที่มีอยู่และไม่ได้ฝึกโมเดลใหม่

ระบบใช้ ONNX Runtime CUDAExecutionProvider บน RTX 5070 Ti Laptop GPU

MODEL	VALIDATION IOU	DICE	MEAN LATENCY	FPS
BASELINE	0.95102	0.97427	13.88 ms	72.07
MODEL A	0.95779	0.97795	17.29 ms	57.84
MODEL B	0.95299	0.97537	13.91 ms	71.87

Model A มีค่า Validation IoU สูงที่สุด แต่มี Inference Latency สูงที่สุดเช่นกัน

Model B มีความแม่นยำสูงกว่า Baseline เล็กน้อย และมี Mean Latency ใกล้เคียง Baseline

ผลดังกล่าวแสดงว่า Model A และ Model B มีข้อได้เปรียบแตกต่างกันระหว่าง Accuracy และ Runtime Performance

ONNX Numerical Parity

แม้โมเดลสามารถ Export เป็น ONNX FP16 ได้ แต่การตรวจสอบ Stateful Numerical Parity ยังพบความแตกต่างระหว่าง PyTorch และ ONNX

การทดลอง Five-Frame Parity ที่ 512×512 ได้ผลดังนี้

MODEL	MAX ABSOLUTE ERROR	MEAN ABSOLUTE ERROR
BASELINE	0.15957	0.00236
MODEL A	0.66516	0.00591
MODEL B	0.11301	0.00204

การทดลองรอบล่าสุดที่ใช้ Parity Threshold ไม่เกิน 0.08 ระบุว่า Model A และ Model B ยังไม่ผ่านเกณฑ์

ดังนั้นแม้โมเดลจะมี Validation IoU สูงและสามารถรัน ONNX ได้ แต่ยังไม่สามารถรับรองความถูกต้องของ Stateful ONNX FP16 สำหรับ Deployment ภายใต้เกณฑ์ที่กำหนด

Experimental Results Summary

ผลการทดลองสามารถสรุปได้ว่า

- Model A มี Validation IoU สูงที่สุดใน Final Fine-tuning
- Model B ลดจำนวน Parameters และ Model Size ได้มากที่สุดในกลุ่ม Final Models
- Model B มี PyTorch FP16 FPS สูงกว่า Model A
- ONNX FP16 ยังมีปัญหา Numerical Parity
- ยังไม่มี Final Test Metrics ที่ยืนยันได้ครบถ้วนและยังไม่มี On-Device Jetson Nano Benchmark

จึงไม่สามารถสรุปว่าโมเดลใดเป็น Production-Ready Model ได้จากผลปัจจุบัน

Results Analysis and Discussion

Accuracy versus Model Size

ผลการทดลองแสดงให้เห็นว่า Structural Compression สามารถลดจำนวน Parameters ของโมเดลได้จริง โดย Model A ลดลง 9.35% และ Model B ลดลง 12.12%

Model A รักษาค่า Validation IoU ได้สูงกว่า Model B ขณะที่ Model B มีโครงสร้างที่เล็กกว่า

ดังนั้นการเลือกโมเดลจึงขึ้นอยู่กับความสำคัญระหว่าง Prediction Accuracy และ Model Size ของระบบเป้าหมาย

Effectiveness of Compression Techniques

จาก Compression Search พบว่า Unstructured Pruning ไม่ช่วยลดขนาด Dense Checkpoint ในรูปแบบที่ใช้ในการทดลอง

SVD50 สามารถลด Parameters โดยรักษา Accuracy ได้ดี ขณะที่ Channel Slimming เพิ่มความสามารถในการลดขนาดโครงสร้าง

การผสม SVD และ Channel Slimming ใน Model B ทำให้จำนวน Parameters ลดลงมากกว่า Model A แต่ไม่ได้หมายความว่าจะรวดเร็วกว่าทุก Runtime

Accuracy versus Inference Speed

ผล PyTorch FP16 แสดงว่า Model B มี FPS สูงกว่า Model A

แต่ผล ONNX FP16 ที่ 512×512 พบว่า Model B มี Mean Latency ใกล้เคียง Baseline ขณะที่ Model A ช้ากว่า Baseline แม้มีจำนวน Parameters น้อยกว่า

ผลดังกล่าวแสดงว่าการลด Parameters ไม่ได้ทำให้ Inference Latency ลดลงเสมอไป เพราะ Low-Rank Factorization และ Operator Execution อาจมี Overhead เพิ่มเติม

Knowledge Distillation and Augmentation

การใช้ Knowledge Distillation ร่วมกับ Recovery Training ช่วยให้ Student Models ได้รับ Training Signals จาก Teacher Predictions

นอกจากนี้ Gaussian Blur และ Noise ถูกเพิ่มเข้ามาเพื่อเพิ่มความหลากหลายของ Training Images

อย่างไรก็ตาม ยังไม่มี Controlled Ablation ที่แยกผลของ KD และ Augmentation ออกจาก Recovery Fine-tuning อย่างสมบูรณ์ จึงไม่สามารถระบุได้ว่าปัจจัยใดทำให้ Accuracy เพิ่มขึ้นมากที่สุด

Limitations

ข้อจำกัดหลักของการทดลอง ได้แก่

1. ผล Final Test ยังมีข้อจำกัดด้าน Data Provenance
2. ONNX FP16 ยังไม่ผ่าน Stateful Numerical Parity Gate
3. การวัด FPS เป็น Model-Only Benchmark ไม่ใช่ End-to-End Application FPS
4. ยังไม่มีผล Benchmark บน Jetson Nano จริง
5. ยังไม่มีการประเมิน Background Reconstruction หรือ Temporal Video Removal Quality

ดังนั้นผลการทดลองที่ยืนยันได้ในปัจจุบันจึงอยู่ในขอบเขตของ Model Compression และ Human Segmentation Performance

Data Transmission to Target Device

ในขั้นตอนการนำไปประยุกต์ใช้งานจริง ระบบฝั่งต้นทาง (เครื่องที่มีกล้องเว็บแคมและรันโมเดล AI) จะทำการส่งภาพและผลการตัดส่วนบุคคลไปยัง Jetson Nano ปลายทางผ่านระบบเครือข่าย Local Network (LAN) โดยมีขั้นตอนการทำงานดังนี้:

1. การประมวลผลและสร้างหน้ากากบุคคล (Inference & Masking):

- โปรแกรมดึงภาพวิดีโอสดจากกล้องเว็บแคม ป้อนเข้าสู่โมเดลบีบอัด (ONNX FP16) เพื่อทำการแบ่งส่วนภาพบุคคล (Foreground Human Segmentation) ออกมาเป็นภาพหน้ากากขาว-ดำ (Binary Mask)

2. การบีบอัดและรวมแพ็กเก็ตข้อมูล (Encoding & Packaging):

- บีบอัด **ภาพกล้องต้นฉบับ** เป็นไฟล์ภาพ JPEG (คุณภาพ 85%) เพื่อประหยัดแบนด์วิดท์
- บีบอัด **ภาพหน้ากากคน (Mask)** เป็นไฟล์ภาพ PNG เพื่อรักษาความคมชัดของขอบคน
- นำภาพทั้งสองและข้อมูลกำกับ (เช่น หมายเลขเฟรม และขนาดไฟล์) มารวมเข้าด้วยกันเป็นแพ็กเก็ตเดียว (Packet)

3. การส่งข้อมูลผ่านเครือข่าย (TCP Socket Streaming):

- ส่งแพ็กเก็ตข้อมูลผ่านโปรโตคอล **TCP Socket** ไปยังหมายเลข IP ของ Jetson Nano เครื่องปลายทางที่พอร์ต 5000
- มีการตั้งค่า TCP_NODELAY เพื่อให้ระบบส่งข้อมูลออกไปทันทีที่มีเฟรมใหม่โดยไม่ต้องรอสะสมบัฟเฟอร์ ช่วยลดความหน่วง (Latency) และทำให้ภาพที่ส่งไปแสดงผลที่เครื่องปลายทางมีความลื่นไหลแบบเรียลไทม์ (Real-time)

References and Source Code

10.2 Project Source Code

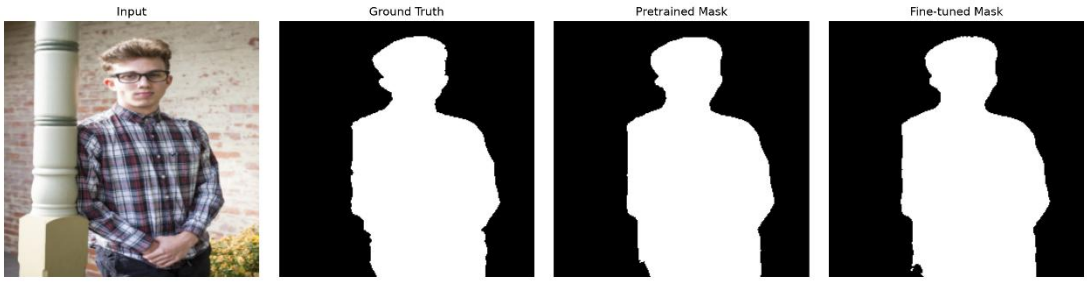
GitHub Repository:

https://github.com/tawan123456789/Human-filter-for-video

Appendix — Supporting Evidence

Appendix A: ตัวอย่าง Dataset และ Ground Truth Masks

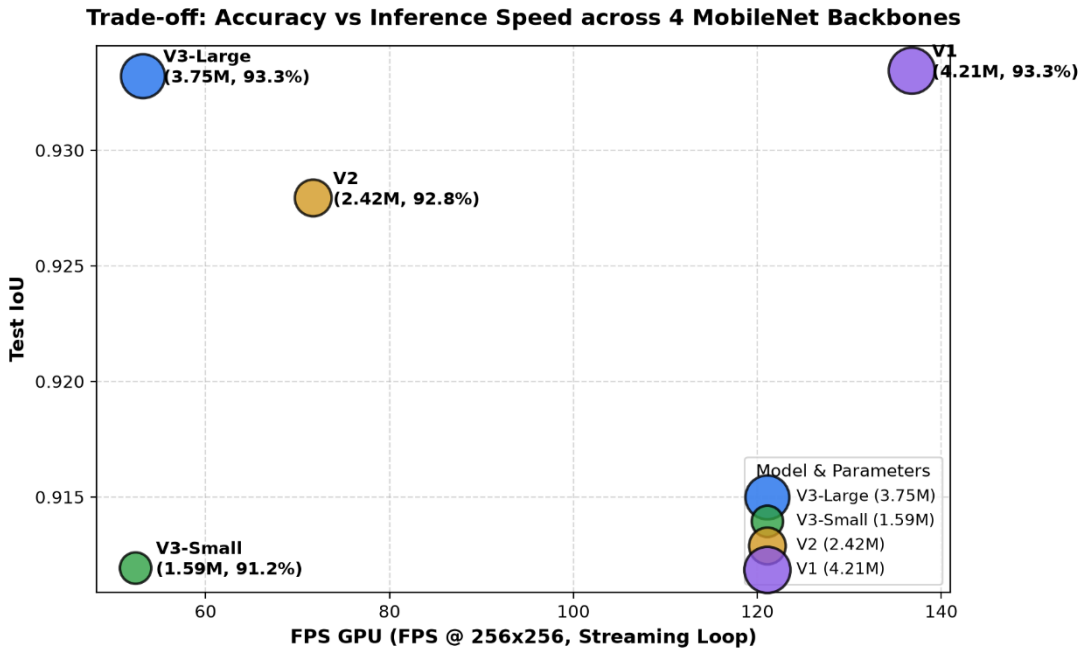
ภาพตัวอย่างนี้แสดง Input, Ground Truth Mask, ผลจาก Pretrained Model และผลหลัง Fine-tuning เพื่อให้เห็นความแตกต่างของ Mask ในตัวอย่างเดียว ผลในภาพเป็นการสาธิตเชิงคุณภาพ ไม่ใช่ค่าความแม่นยำเฉลี่ยของชุดข้อมูล



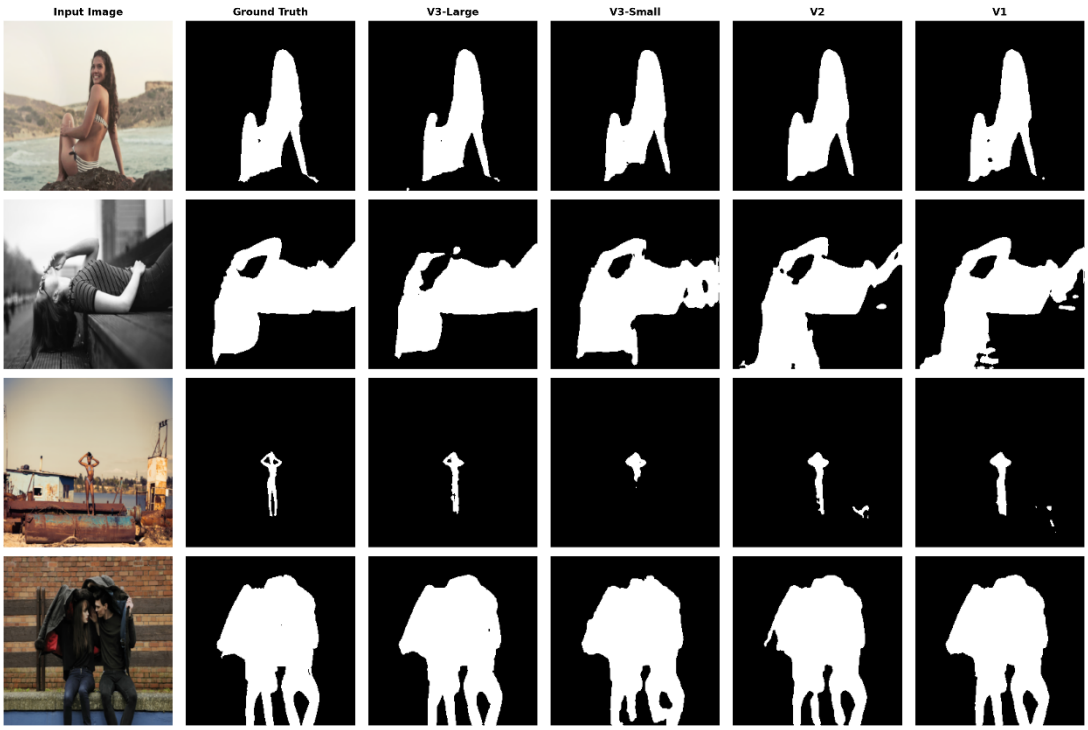
รูป *A*.1 ตัวอย่าง *Input Image, Ground Truth, Pretrained Mask* และ *Fine-Tuned Mask*

Appendix B: RVM Architecture และ MobileNet Backbone Comparison

กราฟและภาพตัวอย่างด้านล่างแสดงผลเปรียบเทียบ RVM ที่ใช้ MobileNet Backbone 4 รูปแบบ ทั้งด้าน Test IoU, GPU FPS และผล Human Mask เมื่อเทียบกับ Ground Truth



รูป *B.*1 ความสัมพันธ์ระหว่าง *Test IoU* และ *GPU FPS* ของ *MobileNet Backbone* ทั้ง 4 รูปแบบ ที่ความละเอียด 256 × 256

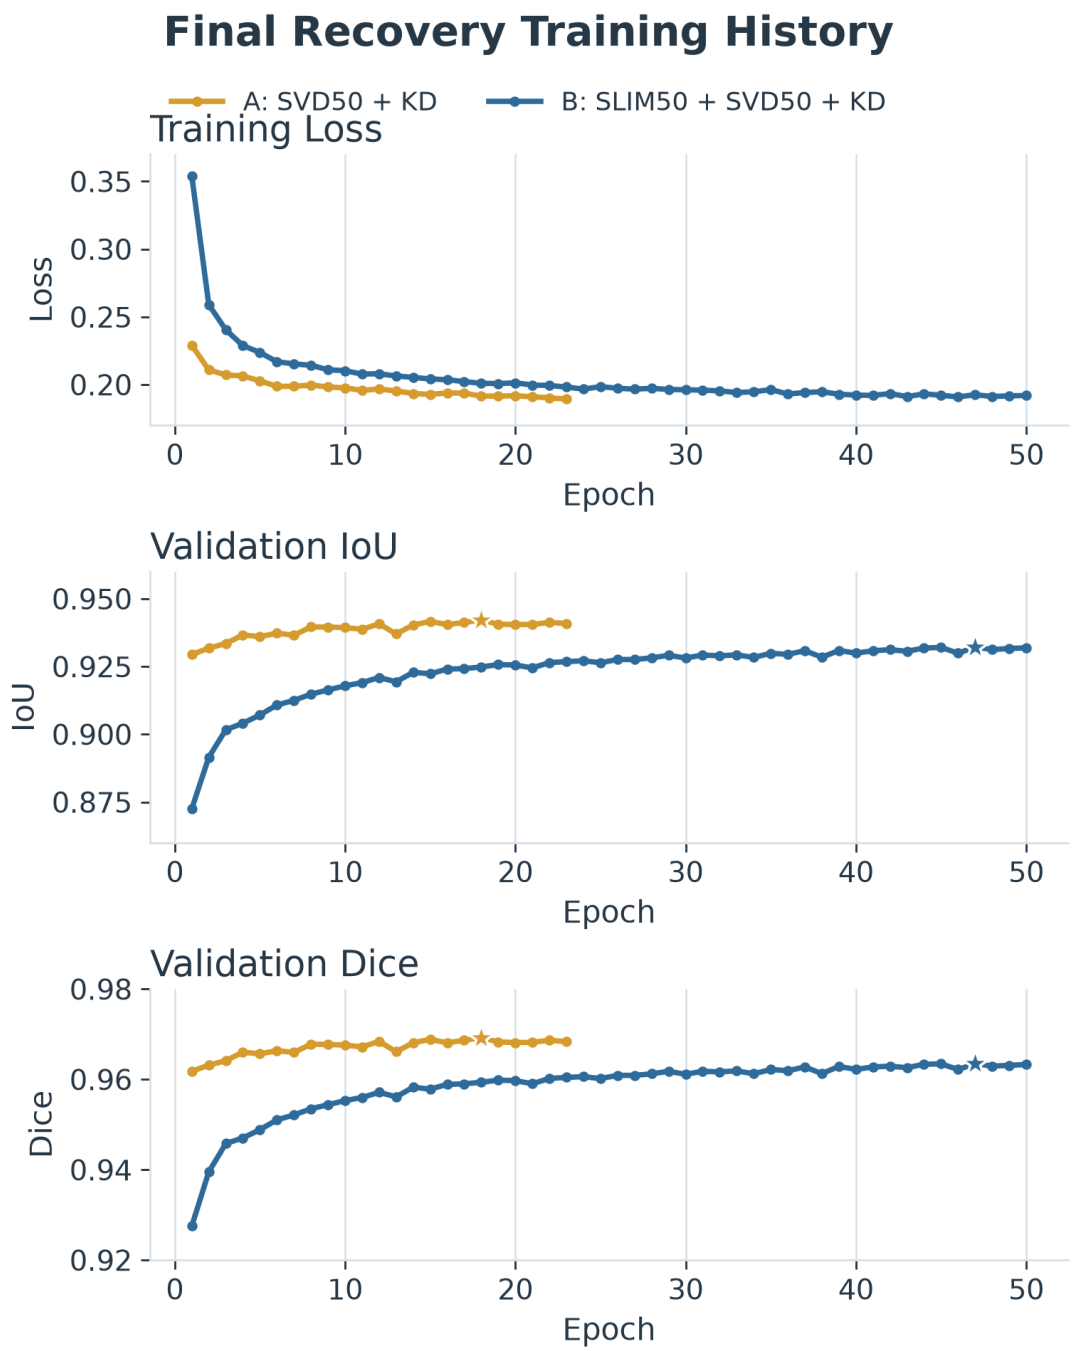


รูป *B.*2 ตัวอย่าง *Input, Ground Truth* และผล *Human Mask* จาก *RVM-MobileNet Backbone* ทั้ง 4 รูปแบบ

ภาพตัวอย่างนี้ใช้แสดงความแตกต่างเชิงคุณภาพของขอบเขต Mask และไม่ได้แทนการประเมินเชิงสถิติของชุดข้อมูลทั้งหมด

Appendix C: Training Configurations และ Fine-Tuning Results

กราฟแสดง Training Loss, Validation IoU และ Validation Dice จากรอบ Recovery Training ล่าสุด โดย Model A ใช้ SVD50 + Knowledge Distillation และ Model B ใช้ SLIM50 + SVD50 + Knowledge Distillation

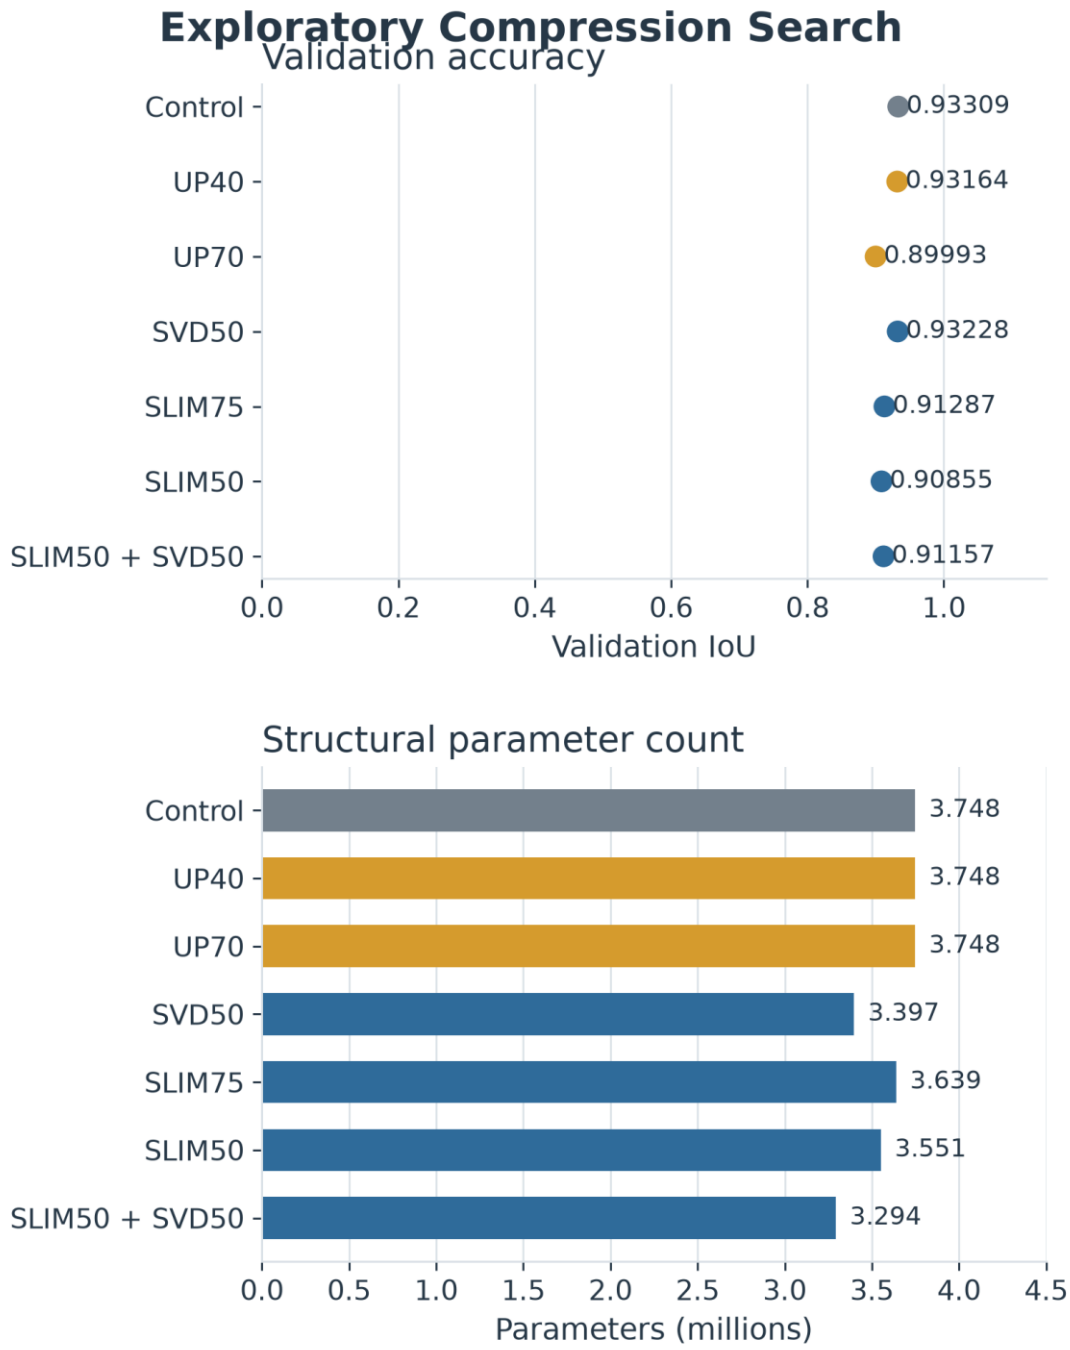


รูป C.1 *Training Loss* และ *Validation Metrics* ราย *Epoch* ของ *Model A* และ *Model B;* ดาวแสดง *Best Epoch*

Model A ฝึก 23 Epochs และเลือก Best Epoch 18; Model B ฝึก 50 Epochs และเลือก Best Epoch 47 ค่า Training ใช้ Input 256 × 256, Batch Size 8, Seed 42, KD Weight 0.2 และ Temperature 2.0 โดยสุ่ม Gaussian Blur/Noise เฉพาะ Training Images

Appendix D: Compression Experiment Results

กราฟนี้สรุปผล Compression Search ระยะแรกสำหรับเปรียบเทียบ Validation IoU และจำนวน Parameters ของแต่ละวิธี

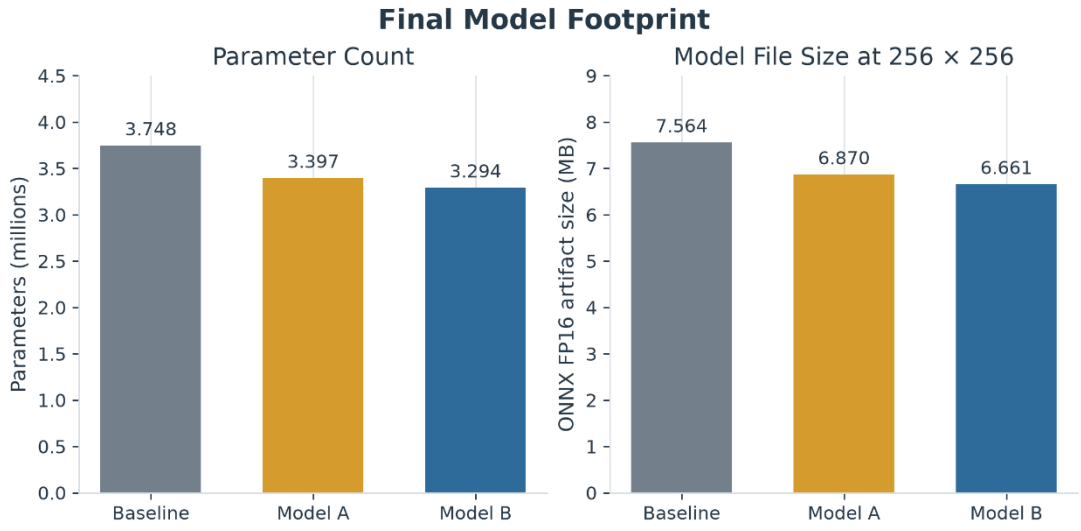


รูป *D.1 Validation IoU* และจำนวน *Parameters* ใน *Exploratory Compression Search*

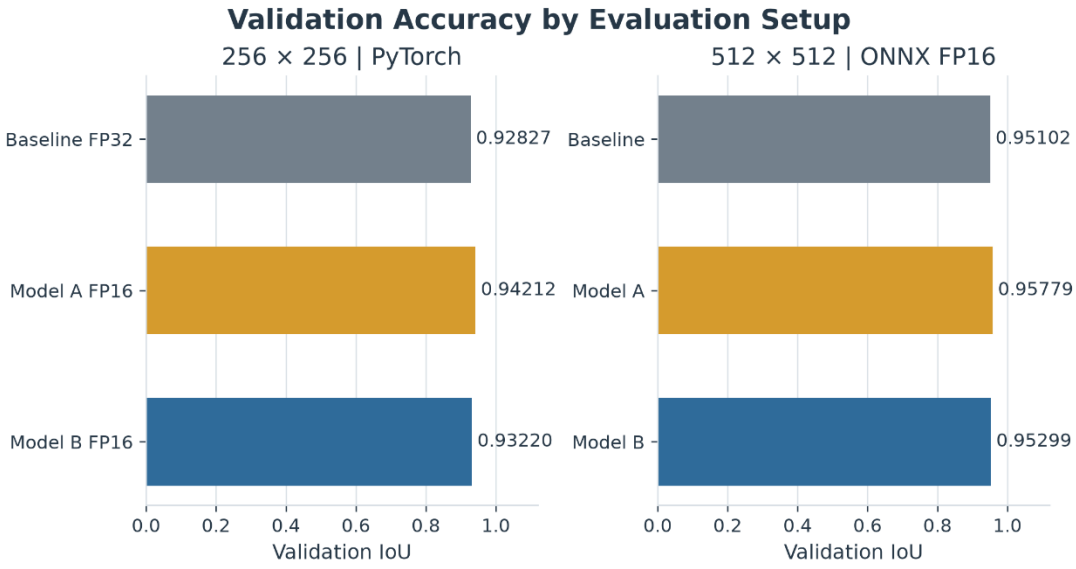
ผลในรูป D.1 มาจาก Compression Search บน Split รุ่นเก่า ใช้เพื่อเปรียบเทียบเทคนิคเบื้องต้นเท่านั้น ไม่ใช่ Final Model Comparison; ค่า Final Models สรุปแยกไว้ใน Appendix E

Appendix E: Model Size, Accuracy และ FPS Comparison Graphs

กราฟต่อไปนี้สรุปผล Final Models โดยแยกค่าตามรูปแบบ Precision, Runtime และ Input Resolution ที่ใช้วัด

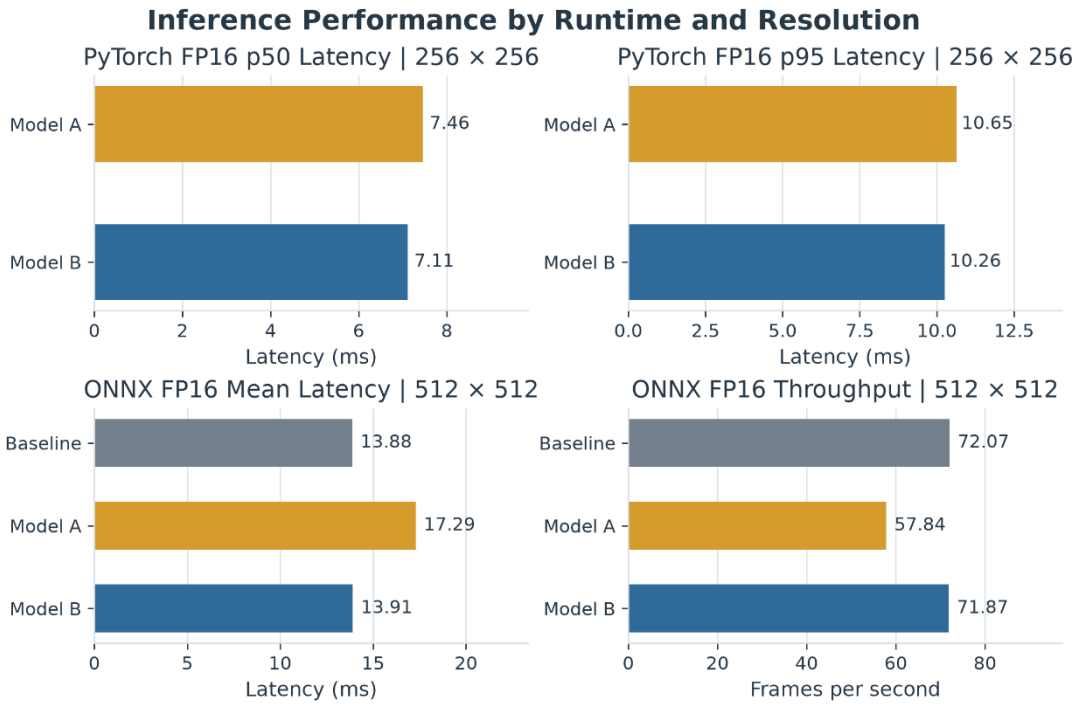


รูป *E.*1 จำนวนพารามิเตอร์และขนาดไฟล์ *ONNX FP*16 ของ *Baseline, Model A* และ *Model B*



รูป *E.2 Validation IoU* แยกตามการประเมิน *PyTorch* ที่ 256 × 256 และ *ONNX FP*16 ที่ 512 × 512

หมายเหตุ: ผล 256 × 256 แสดง Baseline FP32 และ Model A/B FP16 ส่วนผล 512 × 512 เป็น ONNX FP16 จึงควรพิจารณาแยกชุดการประเมิน

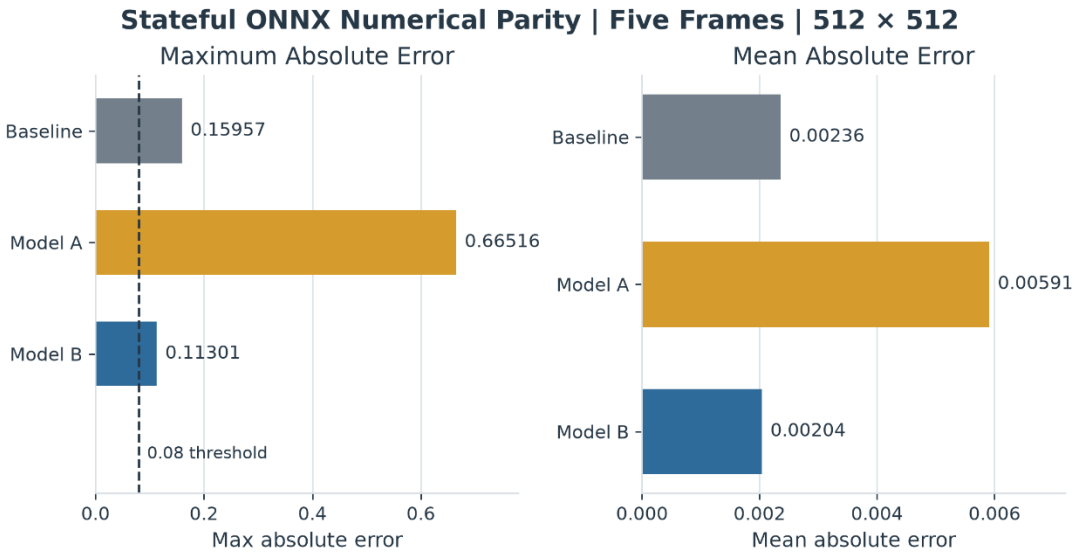


รูป *E.*3 *Latency* และ *Throughput* ของ *PyTorch FP*16 ที่ 256 × 256 และ *ONNX FP*16 ที่ 512 × 512

PyTorch FP16 วัดบน RTX 5070 Ti Laptop GPU โดยแสดง p50/p95 latency และ FPS ส่วน ONNX FP16 ใช้ ONNX Runtime CUDAExecutionProvider และแสดง Mean Latency กับ FPS ผลเหล่านี้เป็น Model-Only Benchmark

Appendix F: ONNX Numerical Parity Results

กราฟแสดงความคลาดเคลื่อนระหว่าง PyTorch กับ ONNX FP16 ในการส่ง Recurrent States ต่อเนื่อง 5 เฟรม ที่ Input Resolution 512 × 512 เส้นประแสดงเกณฑ์ Max Absolute Error ไม่เกิน 0.08

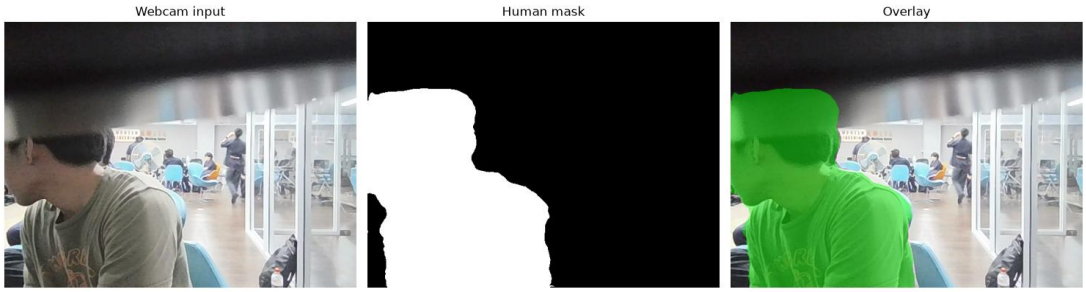


รูป *F.1 Max* และ *Mean Absolute Error* สำหรับการทดสอบ *Stateful ONNX Numerical Parity*

ค่าของทั้ง Baseline, Model A และ Model B สูงกว่าเกณฑ์ Max Absolute Error ที่กำหนด จึงยังไม่ผ่าน Parity Gate สำหรับ Deployment

Appendix G: Webcam Application Screenshots

ภาพนี้แสดง Webcam Input, Human Mask และ Overlay จากตัวอย่างแอปพลิเคชันทดลอง

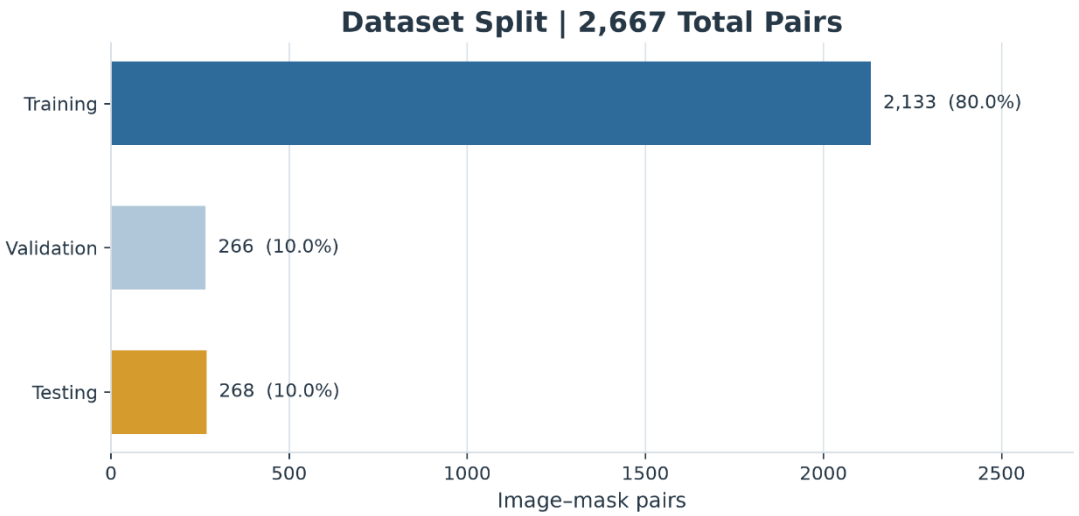


รูป *G.*1 ตัวอย่าง *Webcam Input, Human Mask* และ *Overlay*

ภาพนี้เป็นตัวอย่างการแสดงผล Segmentation ไม่ใช่หลักฐานการวัด Benchmark บน Jetson Nano; รายงานยังไม่มีผล On-Device Benchmark

Appendix H: Dataset Split Audit และ Reproducibility Information

กราฟแสดงจำนวนคู่ภาพและ Mask ในแต่ละ Partition จากข้อมูลทั้งหมด 2,667 คู่



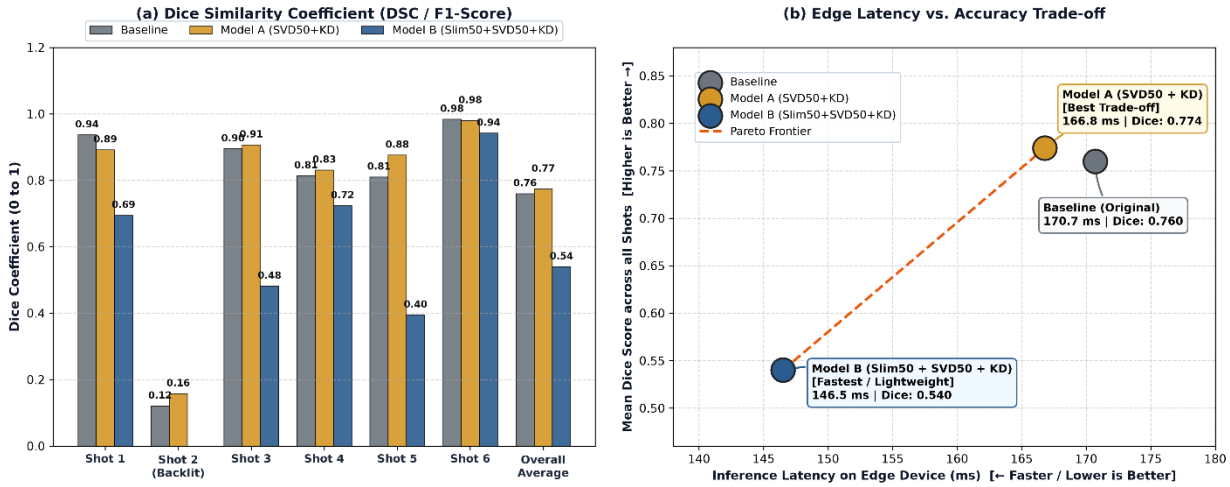
รูป I.1 จำนวนและสัดส่วนตัวอย่าง *Training, Validation* และ *Testing*

การเตรียมข้อมูลใช้ RGB และ Bilinear Interpolation สำหรับภาพ ส่วน Mask ใช้ Nearest-Neighbor Interpolation และแปลงค่าภาพให้อยู่ในช่วง 0–1 ระหว่าง Training สุ่มใช้ Gaussian Blur โอกาส 25% (Radius 0.3–1.2) และ Gaussian Noise โอกาส 35% (Standard Deviation 0.01–0.05) โดยไม่สุ่ม Augmentation กับ Validation และ Test

Appendix I: Live Webcam Evaluation และการประเมินเชิงเปรียบเทียบ (Dice & IoU Benchmark)

การทดลองนี้เป็นการประเมินความสามารถในการแบ่งส่วนภาพบุคคล (Human Segmentation) จากสัญญาณภาพกล้องเว็บแคมแบบสด (Live Webcam Feed) เพื่อทดสอบความทนทานต่อสภาวะแวดล้อมจริง โดยเปรียบเทียบระหว่างโมเดลตั้งต้น (Baseline), Model A (SVD50 + KD) และ Model B (SLIM50 + SVD50 + KD) เทียบกับหน้ากากความจริงภาคพื้น (Ground Truth) ที่กำหนดขึ้นในระดับพิกเซล

MODEL	MEAN IOU	MEAN DICE	MEAN LATENCY	MEAN LIVE FPS	MEAN MODEL FPS
BASELINE	0.6818	0.7601	13.88 ms	3.73	5.88
MODEL A	0.6953	0.7740	17.29 ms	3.87	6.10
MODEL B	0.4257	0.5397	13.91 ms	4.33	6.78



รูป *H.1: (a)* ค่า *Dice Similarity Coefficient* เปรียบเทียบทั้ง *3* โมเดลในแต่ละสภาวะทดสอบ และ *(b)* ความสัมพันธ์ระหว่าง *Inference Latency* กับ *Dice Score* แสดงแนวคิดความคุ้มค่าแบบ *Pareto Frontier* บน *Edge Device*



รูป *H.2:* ภาพเปรียบเทียบผลการทำนายจริงเชิงคุณภาพจากกล้องเว็บแคมทั้ง *6* สภาวะ: (*a) Ground Truth Reference Mask* (หน้ากากสีเขียวสว่าง), *(b) Baseline* (หน้ากากสีเขียว), *(c) Model A* (หน้ากากสีฟ้า), และ (*d) Model B* (หน้ากากสีชมพู)

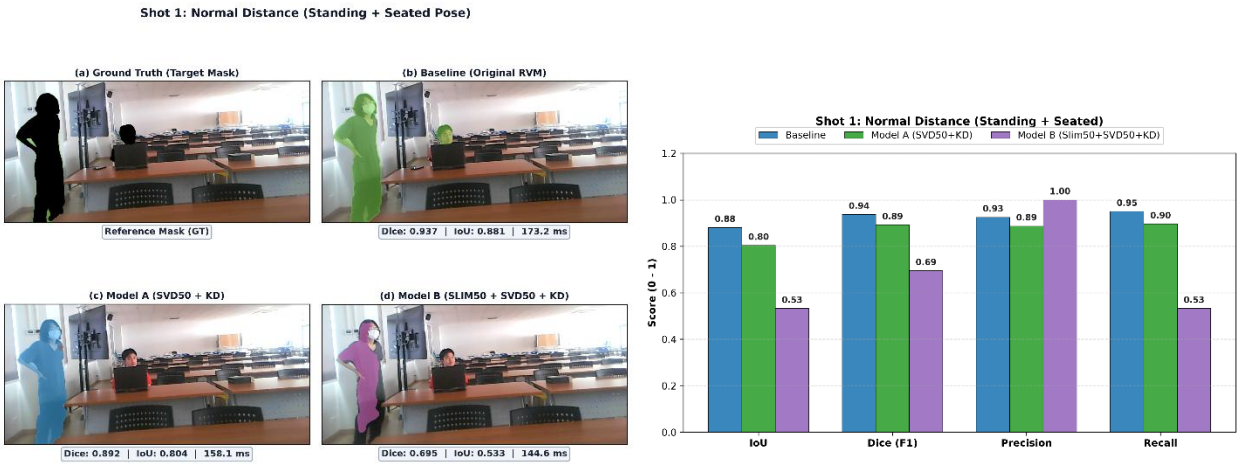
หมายเหตุระเบียบวิธีการประเมิน (Evaluation Methodology Note):

เนื่องจากการทดสอบบนระบบ Live Webcam Feed กระทำในลักษณะการสตรีมภาพต่อเนื่องตามเวลาจริง ทำให้เฟรมภาพที่บันทึกของแต่ละโมเดลอาจมีความแตกต่างของการเคลื่อนไหวเล็กน้อยตามช่วงเวลา การประเมินค่า IoU และ Dice Similarity Coefficient ในการทดลองนี้จึงดำเนินการในลักษณะ Frame-Specific Ground Truth Pairing โดยทำการกำหนดหน้ากากความจริงภาคพื้น (Ground Truth Mask) ให้แก่เฟรมภาพของแต่ละโมเดลแยกอิสระในระดับพิกเซล เพื่อให้การวัดความแม่นยำสะท้อนสมรรถนะการแบ่งส่วนภาพบุคคลเทียบกับเป้าหมายจริงของเฟรมนั้น ๆ ได้อย่างถูกต้อง เที่ยงตรง และปราศจากความคลาดเคลื่อนจากการขยับตัวของผู้ถูกทดสอบ

การวิเคราะห์ปัญหาและข้อจำกัดที่พบ (Problems and Limitations Analysis)

จากการประเมินผลการแบ่งส่วนภาพบุคคลเชิงเวลาจริงบนอุปกรณ์ประมวลผลปลายทาง NVIDIA Jetson Nano ในสภาวะแวดล้อมและสถานการณ์จำลองที่แตกต่างกันทั้งหมด 6 รูปแบบ (6 Test Shots) สามารถวิเคราะห์พฤติกรรมของโมเดล ปัญหา และข้อจำกัดเฉพาะของแต่ละสภาวะ ได้ดังต่อไปนี้:

Shot 1: Normal Distance (Standing + Seated Pose)

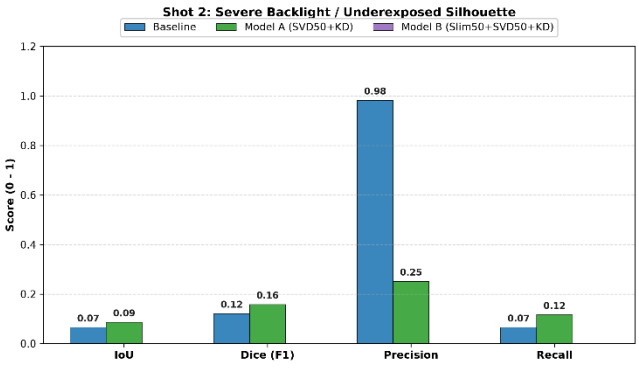


การวิเคราะห์และข้อจำกัดที่พบใน Shot 1:

- **สภาพแวดล้อม:** สภาพแสงไฟห้องเรียนปกติ มีบุคคลยืนอยู่ด้านหน้า และบุคคลอีกคนหนึ่งนั่งทำงานอยู่หลังโต๊ะแล็ปท็อป
- **Baseline:** เป็นโมเดลเดียวที่สามารถตรวจจับบุคคลได้ครบถ้วนทั้ง 2 ตำแหน่งในเฟรมภาพ โดยครอบคลุมทั้งบุคคลที่ยืนอยู่ด้านซ้ายและส่วนศีรษะของบุคคลที่นั่งอยู่หลังจอแล็ปท็อป ส่งผลให้ได้ค่า Recall สูงถึง 0.9496 และ Dice สูงสุดที่ 0.9370
- **ปัญหาที่พบใน Model A (SVD50 + KD):** แม้ว่าจะสามารถตัดขอบรอบตัวบุคคลที่ยืนอยู่ด้านซ้ายได้อย่างเรียบเนียนและแม่นยำ แต่ Model A ไม่สามารถตรวจจับบุคคลที่นั่งอยู่หลังจอแล็ปท็อปได้เลย (เกิด False Negative) เนื่องจากสัดส่วนของบุคคลที่โผล่พ้นจอโน้ตบุ๊กมีขนาดเล็กและมีมุมมองการถูกบดบังบางส่วน (Partial Occlusion) ส่งผลให้ค่า Recall ลดทอนลงมาอยู่ที่ 0.8961 และ Dice ลดลงมาอยู่ที่ 0.8915
- **ปัญหาที่พบใน Model B (SLIM50 + SVD50 + KD):** การตัดลดแชนแนลลง 50% ทำให้สูญเสียความสามารถในการตรวจจับทั้งสองกรณีอย่างรุนแรง โดยไม่สามารถตรวจจับบุคคลที่นั่งหลังจอแล็ปท็อปได้เช่นเดียวกับ Model A และสำหรับบุคคลที่ยืนอยู่ด้านซ้าย โมเดลสามารถจับพื้นที่ได้เพียงครึ่งซีกตัวด้านขวาเท่านั้น (แขนและลำตัวซีกซ้ายหลุดหายไปจากมาสก์) ส่งผลให้ค่า Recall ตกฮวบลงเหลือเพียง **0.5327** และค่า Dice ลดลงเหลือ **0.6951**

Shot 2: Severe Backlight / Silhouette (Door Lighting)

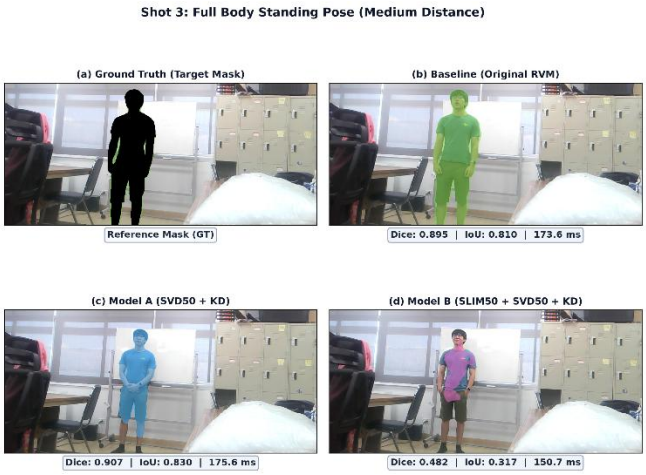


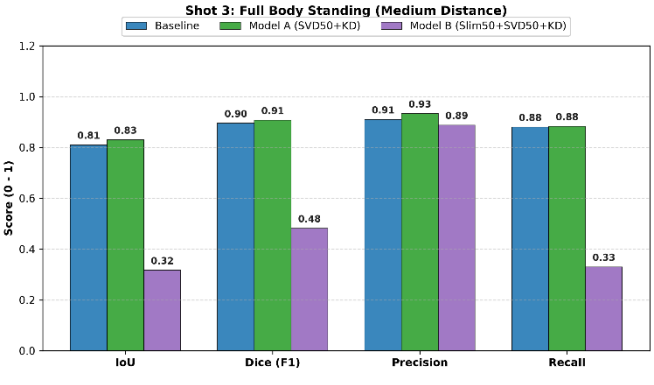


การวิเคราะห์และข้อจำกัดที่พบใน Shot 2:

- **สภาพแวดล้อม:** สภาวะย้อนแสงรุนแรง (Backlit Stress-test) โดยบุคคล 3 คนยืนอยู่หน้าประตูกระจกที่มีแสงแดดส่องเข้ามา กล้องเว็บแคมลดค่า Exposure อัตโนมัติทำให้บุคคลกลายเป็นเงามืด (Silhouette)
- **ปัญหาด้าน Feature สูญหาย:** โมเดลทั้ง 3 ตัวล้มเหลวในการตรวจจับบุคคลหน้าประตูเนื่องจากคอนทราสต์และสีเสื้อผ้าจมหายไปในเงามืด โดย Baseline ตรวจจับได้เฉพาะคนที่ 2 และ 3 เล็กน้อย (Dice 0.1212)
- **ปัญหาการทำนายวัตถุผิดพลาด (False Positive on Props):** ใน Model A และ Model B ตัวโมเดลเกิดความสับสนและจำแนก "พัดลมตั้งโต๊ะสีเขียว/ฟ้า" ด้านหน้าว่าเป็นมนุษย์ และ Model B ไม่สามารถตรวจจับมนุษย์จริงได้เลยแม้แต่พิกเซลเดียว (Dice 0.0000) ถือเป็นจุดอ่อนสำคัญของโมเดลที่ต้องการระบบ Hardware WDR/HDR หรือ CLAHE เข้ามาช่วยปรับแสง

Shot 3: Full Body Standing Pose (Medium Distance)

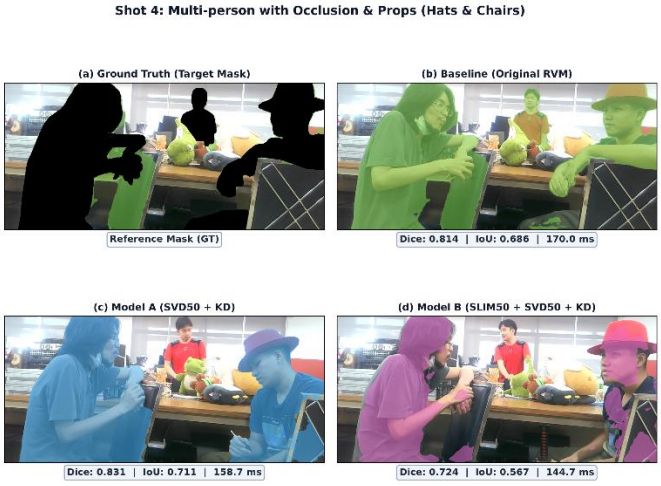


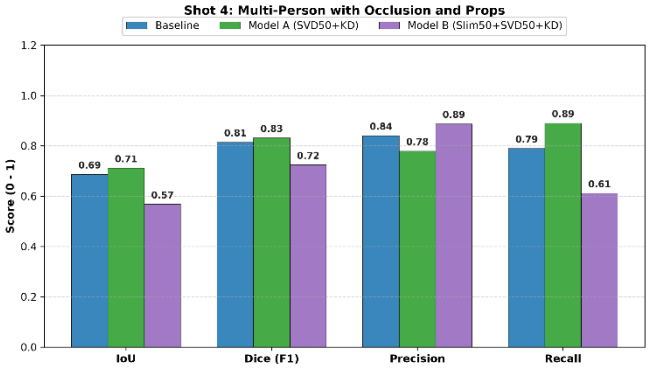


การวิเคราะห์และข้อจำกัดที่พบใน Shot 3:

- **สภาพแวดล้อม:** บุคคลยืนเต็มตัวในระยะกลาง (Medium Distance) สัดส่วนของบุคคลในเฟรมภาพมีขนาดเล็กลงเมื่อเทียบกับพื้นที่ห้อง
- **จุดเด่นของ Model A:** ทำผลงานได้ **ชนะโมเดล Baseline** (Dice 0.9072 เทียบกับ 0.8949, IoU 0.8301 เทียบกับ 0.8098) โดยมาสก์ของ Model A ครอบคลุมตั้งแต่ศีรษะถึงปลายเท้าได้อย่างสม่ำเสมอ
- **ปัญหาความไวต่อสเกล (Scale Sensitivity) ใน Model B:** การบีบอัดแชนแนล 50% ทำให้ความสามารถในการจับวัตถุขนาดเล็กของ Model B ด้อยลงอย่างเห็นได้ชัด โมเดลจับได้เฉพาะเสื้อยืดท่อนบนบางส่วน แต่พื้นที่กางเกงและขาทั้งหมดหลุดหายไป ส่งผลให้ Recall ตกเหลือเพียง 0.3303

Shot 4: Multi-person Conversation with Occlusion & Props

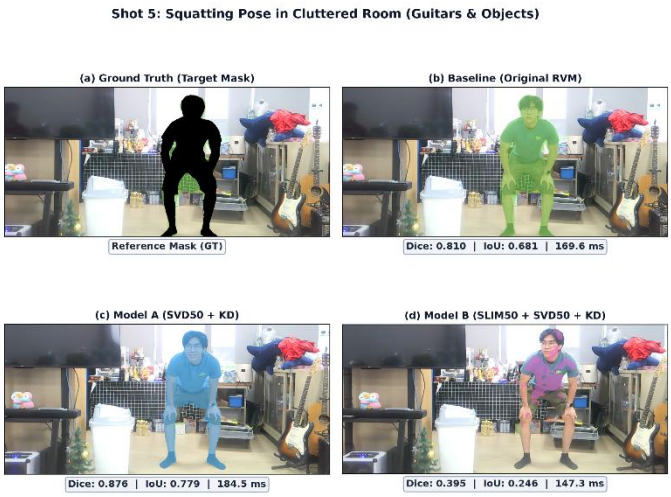


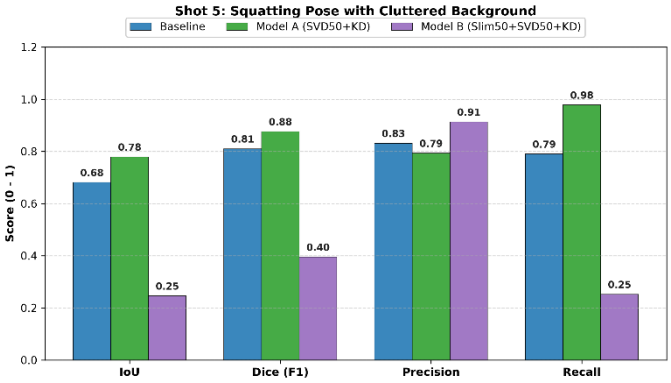


การวิเคราะห์และข้อจำกัดที่พบใน Shot 4:

- **สภาพแวดล้อม:** สภาพแวดล้อมที่มีสิ่งกีดขวางซับซ้อนและมีบุคคลหลายคนในระยะต่างกัน (บุคคลนั่งคุยทางซ้าย, บุคคลสวมหมวกปีกทางขวา และบุคคลยืนอยู่ตรงกลางฉากหลัง)
- **การตรวจจับบุคคลระยะไกลในฉากหลัง (เสื้อสีแดง):** Baseline เป็นโมเดลเดียวที่สามารถตรวจจับบุคคลที่ยืนอยู่ตรงกลางฉากหลังได้ (มีมาสก์สีเขียวคลุมตัวบุคคลด้านหลัง) ในขณะที่ Model A และ Model B ไม่สามารถตรวจจับบุคคลในฉากหลังได้เลย (เกิด False Negative) แสดงให้เห็นว่าโมเดลที่ผ่านการลดขนาด (Compression) มีแนวโน้มที่จะสูญเสียการตอบสนองต่อบุคคลที่มีสเกลขนาดเล็กในระยะไกล
- **ปัญหาการกินพื้นที่โต๊ะและเก้าอี้ (False Positive on Props & Foreground):** ทั้ง Baseline และ Model A ต่างประสบปัญหาการจำแนกวัตถุด้านหน้าผิดพลาด โดย Baseline ดึงเอาพนักพิงเก้าอี้สีเขียวเข้ามาในมาสก์ ส่วน Model A ก็เกิดการล้นของมาสก์สีฟ้าลงไปคลุมพนักพิงเก้าอี้ ขอบโต๊ะด้านหน้าทางซ้าย รวมถึงโครงเก้าอี้ด้านขวาหน้าบุคคลที่สวมหมวกเช่นเดียวกัน
- **การเปรียบเทียบเชิงสถิติ:** สาเหตุที่คะแนนรวมของ Model A ยังคงได้ค่า Dice สูงกว่า Baseline (0.8309 เทียบกับ 0.8137) เกิดจาก Model A สามารถสร้างมาสก์บนตัวบุคคลด้านหน้า 2 คนได้หนาแน่นและครอบคลุมพื้นที่เสื้อผ้าและแขนได้เต็มเม็ดเต็มหน่วยมากกว่า Baseline ที่มีรอยแหว่ง ส่งผลให้ปริมาณ True Positive บนบุคคลด้านหน้าชดเชยการหลุดบุคคลในฉากหลังได้ในเชิงตัวเลข

Shot 5: Squatting Pose in Cluttered Room (Guitars & Objects)

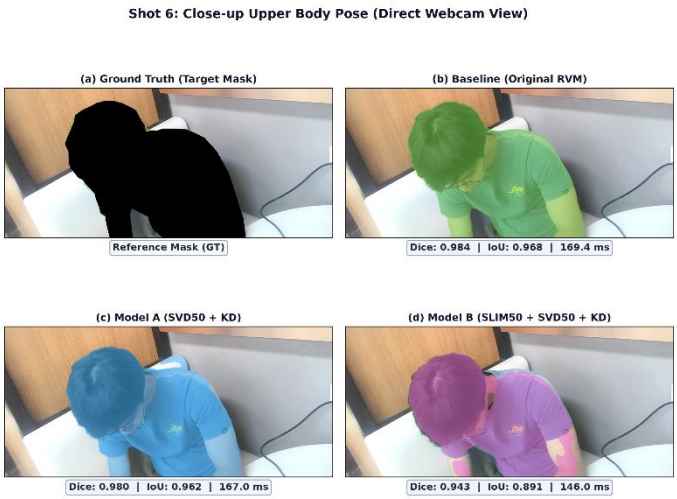


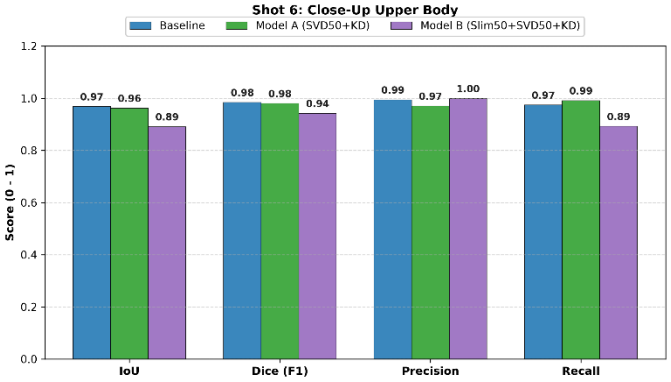


การวิเคราะห์และข้อจำกัดที่พบใน Shot 5:

- **สภาพแวดล้อม:** บุคคลทำท่าย่อตัว (Squatting) ซึ่งเป็นท่าทางที่ไม่ปกติ (Non-standard Human Pose) ท่ามกลางฉากหลังที่มีสิ่งของวางปะปนจำนวนมาก (เครื่องดนตรีกีตาร์ไฟฟ้า, ถังขยะ, โต๊ะวางของ)
- **ปัญหาการแยกแยะช่องว่าง (Hole Segmentation):** Baseline ทำนายผิดพลาดโดยดึงเอา "เก้าอี้ตาข่ายที่อยู่ตรงช่องว่างระหว่างขาทั้งสองข้าง" เข้ามาในมาสก์คน
- **ประสิทธิภาพโดดเด่นของ Model A:** Model A สามารถเจาะช่องว่างระหว่างขาได้อย่างสมบูรณ์แบบ ได้ค่า Recall สูงถึง **0.9783** และค่า Dice สูงถึง **0.8758** (ชนะ Baseline ที่ได้ 0.8101 ถึง +6.57%)
- **ปัญหาของ Model B:** ล้มเหลวในการตรวจจับส่วนขาทั้งหมด โดยจับได้เพียงใบหน้าและบางส่วนของเสื้อยืด (Dice ตกเหลือ 0.3954)

Shot 6: Close-up Upper Body Pose (Direct Webcam View)





การวิเคราะห์และข้อจำกัดที่พบใน Shot 6:

- **สภาพแวดล้อม:** บุคคลนั่งก้มตัวระยะใกล้หน้ากล้อง (Close-up Upper Body) สัดส่วนของร่างกายครอบคลุมพื้นที่ส่วนใหญ่ของเฟรมภาพ
- **ผลงานที่ยอดเยี่ยมในทุกโมเดล:** ทั้ง 3 โมเดลทำคะแนนได้สูงสุดในช็อตนี้ โดย Baseline ได้ Dice **0.9838**, Model A ได้ **0.9804** และ Model B ได้สูงถึง **0.9425**
- **ข้อสรุปสำคัญเกี่ยวกับ Model B:** ผลการทดลองช็อตนี้พิสูจน์ให้เห็นว่า **Model B ไม่ได้สูญเสียความสามารถในการแบ่งส่วนภาพ แต่มีความไวสูงต่อขนาดสเกลของคน (Scale Sensitivity)** เมื่อคนอยู่ใกล้กล้องและมีขนาดใหญ่ Model B สามารถตัดขอบได้อย่างคมชัดและประมวลผลได้เร็วที่สุด
- **ข้อจำกัดด้านฮาร์ดแวร์ Edge (Latency Spike):** ในจังหวะที่บันทึกภาพของ Model A และ B บน Jetson Nano พบอาการค่าเวลา Inference กระโดดขึ้นชั่วขณะ (Spike แตะ 400–500 ms) ซึ่งเป็นข้อจำกัดด้านการบริหารจัดการ Memory I/O และ Unified Memory บนระบบปฏิบัติการของ Jetson Nano ระหว่างการสตรีมมิ่งสด